
SIMGAN

GAN Paper

Learning from Simulated and Unsupervised
Images through Adversarial Training

논문 리뷰(Abstract)

합성 이미지와 실제 이미지의 차이를 줄이는 방법으로 비지도 학습인 SIMGAN을 제시한다.

- **SIMGAN ?**

- **Background**

- 학습용 데이터로 실제 이미지를 사용하여 라벨링 하는 작업은 비용이 High
- -> 그래픽 발전 했으니 합성이미지로 학습할까?
- -> But 실제 이미지와의 차이가 존재
- -> **Simulated + Unsupervised learning**으로 합성사진을 실제처럼 만들자

- **Key Point**

- Self – regularization term
- Local adversarial loss
- Updating the discriminator using history

논문 리뷰(Introduction)

SIMGAN 목적

- 좋은 Refiner Model 생성하는 일
 - 즉, 합성 이미지를 실제 이미지처럼 변환하는 모델을 생성
 - 이 때 합성 이미지의 정보는 유지하면서 동시에 Realism을 향상
 - 예) 눈 전체 모양
 - Refiner를 학습시키기 위한 데이터 : Unlabeled 된 실제 이미지


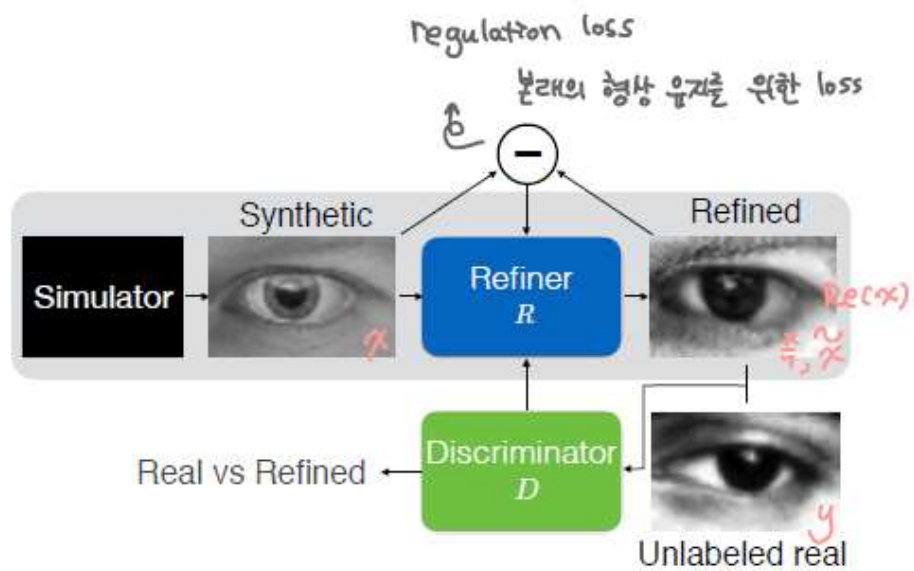


Figure 1. Simulated+Unsupervised (S+U) learning. The task is to learn a model that improves the realism of synthetic images from a simulator using unlabeled real data, while preserving the annotation information.

논문 리뷰(Introduction)

SIMGAN 구조



논문 리뷰(Introduction)

Refiner는 local adversarial loss 및 self regulation loss를 최소화하는 방향으로 학습한다. Self-regularization이란 합성 이미지와 실제 이미지의 차이를 최소화 하는 손실함수이며 이를 이용하여 합성이미지의 정보를 유지한다.

• Contribution

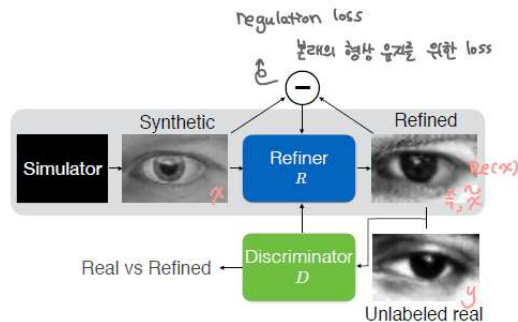
- 합성 이미지를 정제하는 S+U Learning을 제시
- 합성 이미지의 현실성을 높임
 - Adversarial loss and a self-regularization loss를 혼합한 손실함수 사용
 - Refiner 모델 학습에 이용
- GAN 훈련 프레임워크 수정
 - Training 안정화
 - 인공적인 이미지를 생성하지 않도록 함
- 시뮬레이터 출력의 현실성 향상을 여러 실험으로 증명
 - 심층 신경망 훈련을 통해 인간의 라벨링 작업없이 결과 도출 가능

Key Point

Refiner의 손실함수를 소개한다.

• Refiner Loss Funtion

- Local adversarial loss
 - 일반적인 Gan에서의 손실함수
 - 사실성을 증가시키는 목적
- Self-Regulation Loss
 - 합성이미지의 정보 유지 목적



To this end, we propose to learn θ by minimizing a combination of two losses:

$$\mathcal{L}_R(\theta) = \sum_i \ell_{\text{real}}(\theta; \mathbf{x}_i, \mathcal{Y}) + \lambda \ell_{\text{reg}}(\theta; \mathbf{x}_i), \quad (1)$$

where \mathbf{x}_i is the i^{th} synthetic training image. The first part of the cost, ℓ_{real} , adds realism to the synthetic images, while the second part, ℓ_{reg} , preserves the annotation information. In the following sections, we expand this formulation and provide an algorithm to optimize for θ .

$$\mathcal{L}_R(\theta) = -\sum_i \log(1 - D_\phi(R_\theta(\mathbf{x}_i))) + \lambda \|\psi(R_\theta(\mathbf{x}_i)) - \psi(\mathbf{x}_i)\|_1.$$

Key Point

Refined Image history를 이용하여 판별기를 업데이트한다.

- improve the stability of adversarial training
 - by updating the discriminator
 - using a history of refined images,
 - rather than only the ones in the current minibatch.



Figure 3. Illustration of local adversarial loss. The discriminator network outputs a $w \times h$ probability map. The adversarial loss function is the sum of the cross-entropy losses over the local patches.




Figure 4. Illustration of using a history of refined images. See text for details.